



UNIVERSIDADE FEDERAL DO AMAPÁ



DEPARTAMENTO DE CIÊNCIAS EXATAS E TECNOLÓGICAS CIÊNCIA DA
COMPUTAÇÃO

BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO

RELATÓRIO TÉCNICO: RECICLA-AI

ELTON BRAIAN MENDES DA SILVA

KEVIN GABRIEL FARIAS DA SILVA

HUDSON DE JESUS FARIAS DA SILVA

VITÓRIA CHRISTINA ATAIDE RODRIGUES

Docente: Prof. ADOLFO FRANCESCO DE OLIVEIRA COLARES

MACAPÁ

2026

ELTON BRAIAN MENDES DA SILVA

KEVIN GABRIEL FARIAS DA SILVA

HUDSON DE JESUS FARIAS DA SILVA

VITÓRIA CHRISTINA ATAIDE RODRIGUES

RELATÓRIO TÉCNICO: RECICLA-AI

Projeto da disciplina Inteligência Artificial, do Curso de Ciência da Computação, como requisito para avaliação da referida disciplina.

Área de concentração: Bacharelado em Ciência da Computação

Orientador(a): Prof. Adolfo Colares

MACAPÁ

2026

SUMÁRIO

1. PROBLEMA E MOTIVAÇÃO	5
1.1 A Dor do Negócio e do Meio Ambiente	5
1.2 Quem Sofre com Ela?	5
1.3 Por que Inteligência Artificial é a Resposta Certa (e não um if/else)?	5
2. DADOS	6
2.1 O que a Análise Exploratória de Dados (EDA) Revelou	6
2.3 Tratamento de Problemas nos Dados	7
3. METODOLOGIA	7
3.1 Técnicas Testadas	7
3.2 Divisão de Treino, Validação e Teste	8
3.3 Como Evitamos o Overfitting	8
4. RESULTADOS	8
4.1 Justificativa das Métricas Escolhidas	8
4.2 Comparação entre os Modelos (Dados de Teste)	8
Matriz de Confusão (ResNet50 Final - Dados de Teste)	9
Previsão do Modelo	9
4.3 Análise dos Erros do Modelo	9
5. ÉTICA E LIMITAÇÕES	10
5.1 Quem Pode Ser Prejudicado com a Automação?	10
5.2 Viés nos Dados (O Perigo do "Ambiente de Laboratório")	10
5.3 O que o Modelo NÃO Consegue Fazer?	10
6. CONCLUSÃO E PRÓXIMOS PASSOS	11
6.1 O que Fariamos com Mais Um Mês de Desenvolvimento?	11
7. REFERÊNCIAS	12

1. PROBLEMA E MOTIVAÇÃO

1.1 A Dor do Negócio e do Meio Ambiente

O Brasil enfrenta um atraso crítico na gestão de resíduos sólidos. O índice de reciclagem de materiais secos no país varia entre apenas 2,4% e 8,7%. Esse desperdício de recursos que poderiam voltar ao ciclo produtivo gera um prejuízo econômico estimado em R\$ 14 bilhões ao ano.

O principal gargalo para aumentar esses índices está na etapa de **triagem**. Atualmente, a separação de materiais recicláveis (plástico, vidro, papel, metal) é feita de forma predominantemente manual em esteiras de cooperativas, um processo lento, ineficiente e propenso a falhas humanas.

1.2 Quem Sofre com Ela?

- **Catadores e Cooperativas:** Trabalham em condições de extrema insalubridade, expostos a materiais cortantes (vidros quebrados), contaminação biológica e esforço repetitivo em alta velocidade.
- **Municípios:** Sofrem com o aumento dos custos de gestão de resíduos e limpeza urbana (que atingiram R\$ 46 bilhões em 2024), acelerando a saturação de aterros sanitários adequados e inadequados.
- **Indústrias de Reciclagem:** Recebem fardos de materiais altamente contaminados (ex: plástico misturado com vidro ou orgânicos), o que reduz a qualidade da matéria-prima reciclada e encarece o processo de reprocessamento.

1.3 Por que Inteligência Artificial é a Resposta Certa (e não um if/else)?

Na programação tradicional, para identificar um objeto em uma imagem usando lógica estática (if/else), precisaríamos extrair manualmente regras baseadas em cor, tamanho ou geometria. Uma abordagem por regras manuais seria parecida com isto:

```
if cor_predominante == 'verde' and circularidade > 0.8:
```

```
    classificar_como('garrafa_de_vidro')
```

Essa lógica é completamente inviável na vida real devido a três fatores:

1. **Variabilidade Infinita:** Uma garrafa de plástico pode estar amassada, rasgada, sem rótulo, cortada ao meio ou suja de terra. Não existem regras matemáticas simples que consigam descrever todas as formas possíveis que o "lixo" pode assumir.

2. **Interferência de Iluminação e Ângulo:** Mudanças de luz na esteira de triagem alteram as cores capturadas pela câmera. Um objeto visto de cima tem uma silhueta totalmente diferente se estiver de lado.
3. **Extração de Padrões Complexos:** Modelos de Deep Learning (Redes Neurais Convolucionais - CNNs) não dependem de regras manuais. Eles aprendem sozinhos a extrair hierarquias de características das imagens: bordas nas primeiras camadas, texturas e curvas nas intermediárias, e formas complexas (como gargalos de garrafas ou dobras de papelão) nas camadas finais.

2. DADOS

Utilizamos o dataset público *Garbage Classification* do Kaggle. O conjunto de dados é composto por **2.527 imagens** de resíduos, capturadas sob condições controladas de iluminação e fundo. As imagens estão distribuídas em 6 classes principais:

- **Papelão (Cardboard):** 393 imagens
- **Vidro (Glass):** 501 imagens
- **Metal (Metal):** 410 imagens
- **Papel (Paper):** 594 imagens
- **Plástico (Plastic):** 482 imagens
- **Lixo Comum (Trash):** 137 imagens

2.1 O que a Análise Exploratória de Dados (EDA) Revelou

- **Desbalanceamento:** A classe Trash (lixo comum/rejeito) é significativamente menor do que as outras classes (apenas 137 imagens), o que pode fazer o modelo ter dificuldade de identificar o que não é reciclável.
- **Padronização Visual:** As imagens foram tiradas contra fundos brancos ou claros e com o objeto centralizado. Embora excelente para um ambiente de teste inicial, isso representa um grande desafio de generalização para cenários de esteiras reais, onde o fundo é escuro ou metálico e há múltiplos objetos misturados.
- **Semelhança de Texturas:** Algumas imagens de plástico transparente e vidro transparente apresentam alta similaridade visual, assim como papel e papelão sob certas condições de iluminação.

2.3 Tratamento de Problemas nos Dados

Para preparar o dataset para o treinamento dos modelos de Deep Learning, aplicamos o seguinte pipeline de processamento:

1. **Redimensionamento (Resize):** As imagens originais (com resoluções variadas) foram redimensionadas para 224x224 pixels. Essa dimensão é o padrão exigido pelas arquiteturas de redes pré-treinadas e otimiza o consumo de memória RAM/VRAM durante o treino.
2. **Normalização:** Escalamos os valores dos pixels de $[0, 255]$ para o intervalo $[0, 1]$ (ou utilizando a média e o desvio padrão específicos do ImageNet para os modelos de transfer learning) para acelerar a convergência do algoritmo de otimização (Gradient Descent).
3. **Data Augmentation (Aumento de Dados):** Para mitigar o tamanho reduzido do dataset e evitar o overfitting, aplicamos transformações em tempo real nas imagens de treino:
 - Rotação aleatória de até 30 graus.
 - Translação horizontal e vertical (Width/Height Shift) de até 15%.
 - Zoom aleatório de até 20%.
 - Inversão horizontal (Horizontal Flip).
 - Alteração leve de brilho para simular sombras na esteira de triagem.

3. METODOLOGIA

3.1 Técnicas Testadas

Para encontrar o melhor equilíbrio entre velocidade de processamento (essencial para esteiras em movimento) e acurácia de classificação, testamos três abordagens:

1. **CNN Customizada (do zero):** Desenvolvemos uma arquitetura sequencial simples contendo 4 blocos convolucionais (camadas de Convolução 2D seguidas por Max Pooling 2D e ativação ReLU) e uma camada densa final com ativação Softmax para as 6 classes.
 - *Objetivo:* Servir como linha de base (baseline) leve e rápida.
2. **Transfer Learning com MobileNetV2:** Utilizamos a rede MobileNetV2 pré-treinada no dataset ImageNet. Congelamos as camadas convolucionais base e adicionamos uma cabeça de classificação customizada (Global Average Pooling, Dropout de 0.4 e uma camada Densa de saída).
 - *Objetivo:* Obter um modelo extremamente leve, ideal para rodar em dispositivos de borda (Edge Computing) com recursos limitados de hardware localizados na própria esteira.
3. **Transfer Learning com ResNet50 (Final):** Utilizamos a ResNet50 pré-treinada. Adotamos uma estratégia de ajuste fino (*Fine-Tuning*): inicialmente treinamos apenas as camadas superiores e, em seguida, descongelamos os dois últimos blocos residuais para treinar com uma taxa de aprendizado muito baixa ($1e-5$).
 - *Objetivo:* Máxima precisão na extração de texturas complexas de materiais reflexivos (como vidro e metal).

3.2 Divisão de Treino, Validação e Teste

Os dados foram divididos em três conjuntos utilizando amostragem estratificada para manter a proporção original das classes:

- **Treino (70%):** Utilizado para atualizar os pesos da rede neural.
- **Validação (15%):** Utilizado para ajustar hiperparâmetros (taxa de aprendizado, tamanho do lote) e monitorar o overfitting durante as épocas de treino.
- **Teste (15%):** Mantido totalmente isolado e utilizado apenas para a avaliação de performance final.

3.3 Como Evitamos o Overfitting

Modelos complexos de Deep Learning podem memorizar facilmente datasets pequenos de imagens. Para evitar isso, implementamos:

- **Dropout (Descarte Aleatório):** Aplicamos uma taxa de descarte de 40% (Dropout = 0.4) logo antes da camada densa de classificação, forçando a rede a não depender de neurônios específicos.
- **Early Stopping (Parada Precoce):** Configuramos o treinamento para monitorar a perda de validação (`val_loss`). Se a perda parasse de melhorar por 5 épocas consecutivas (paciência = 5), o treinamento era interrompido e os melhores pesos eram restaurados.
- **L2 Regularization:** Aplicada nas camadas densas adicionadas para restringir a magnitude dos pesos.

4. RESULTADOS

4.1 Justificativa das Métricas Escolhidas

Para o problema de triagem de resíduos, a acurácia geral não conta a história toda. Precisamos avaliar o desempenho através de métricas específicas por classe:

- **Precisão (Precision):** Mede quantos itens classificados como um material realmente pertenciam a ele. Uma alta precisão em "Vidro" é crucial se o próximo passo automatizado for triturar o material; misturar plástico rígido por engano pode quebrar as lâminas do triturador.
- **Recall (Sensibilidade):** Mede a capacidade do modelo de capturar todos os itens de uma classe. Um recall baixo para "Plástico" significa que muitas garrafas passarão direto para o aterro comum sem serem recicladas.
- **F1-Score:** Fornece o equilíbrio ideal entre precisão e recall para cada classe de resíduo.

$\text{Recall} = \frac{\text{Verdadeiros Positivos (VP)}}{\text{Verdadeiros Positivos (VP)} + \text{Falsos Negativos (FN)}}$

$\text{F1-Score} = \frac{2 \times \text{Precisão} \times \text{Recall}}{\text{Precisão} + \text{Recall}}$

4.2 Comparação entre os Modelos (Dados de Teste)

MODELO	ACURÁCIA GERAL	F1-SCORE MÉDIO	TEMPO E INFERÊNCIA POR IMG	TAMANHO DO MODELO (MB)
CNN Customizada	61,4%	0,58	8 ms	12 MB
MobileNetV2 (Transfer)	84,2%	0,83	12 ms	16 MB
resNet50 (Fine-Tuning)	89,5%	0,89	28 ms	98 MB

Análise: O modelo **ResNet50** alcançou a melhor performance, chegando a 89,5% de acurácia de classificação. Embora seja o modelo mais pesado e lento para inferência, o tempo de 28 milissegundos por imagem ainda é mais do que suficiente para operar em tempo real em esteiras que se movem a velocidades padrão de triagem (cerca de 1 metro por segundo).

Matriz de Confusão (ResNet50 Final - Dados de Teste)

Previsão do Modelo

	Papelão	Vidro	Metal	Papel	Plástico	Lixo
Papelão	53	1	1	3	1	0
Vidro	0	68	2	1	4	0
Real Metal	1	2	56	0	2	1
Papel	4	0	0	81	3	1
Plástico	2	5	2	2	61	0
Lixo	1	1	2	3	1	13

4.3 Análise dos Erros do Modelo

A matriz de confusão revela alguns padrões interessantes de falha:

1. **Vidro vs. Plástico:** Houve 5 casos em que plásticos foram classificados como vidro e 4 casos em que vidros foram classificados como plástico. Isso ocorre principalmente com garrafas de plástico transparente rígido (PET), que possuem propriedades ópticas (reflexo e refração da luz) muito semelhantes às de garrafas de vidro sob o fundo branco do dataset.
2. **Papelão vs. Papel:** 4 imagens de papel foram confundidas com papelão. Fisicamente, ambos os materiais compartilham fibras de celulose e cores pardas semelhantes, confundindo a textura analisada pelo modelo.
3. **Classe Lixo (Trash):** Obteve o menor desempenho individual devido à falta de dados de treino (baixo suporte). O modelo tendeu a classificar itens de lixo comum erroneamente como papel ou metal devido à presença de embalagens compostas (como pacotes de salgadinho metalizados).

5. ÉTICA E LIMITAÇÕES

5.1 Quem Pode Ser Prejudicado com a Automação?

A implementação de sistemas de inteligência artificial em usinas de reciclagem gera impactos sociais profundos que precisam ser mitigados:

- **Substituição de Mão de Obra Vulnerável:** A triagem de lixo é a principal fonte de renda para milhares de famílias de catadores organizados em cooperativas. Substituir esses postos de trabalho por braços robóticos integrados com câmeras sem um plano de transição pode empurrar essas comunidades de volta para a extrema pobreza. A IA deve ser projetada para atuar como uma **ferramenta de auxílio à segurança** (separando materiais perigosos ou pesados) em vez de uma substituição humana completa.
- **Exclusão de Cooperativas Menores:** O alto custo de instalação de hardware (câmeras de alta velocidade, computadores com GPUs potentes e sistemas pneumáticos de esteira) pode concentrar o mercado de reciclagem em grandes empresas privadas, asfixiando financeiramente as cooperativas menores que não possuem capital para se modernizar.

5.2 Viés nos Dados (O Perigo do "Ambiente de Laboratório")

O dataset do Kaggle foi capturado em ambiente de estúdio, com fundo perfeitamente branco, iluminação controlada e objetos inteiros, limpos e secos.

Na realidade de uma esteira de triagem brasileira:

- Os materiais chegam **amassados, rasgados e deformados**.
- Estão frequentemente **sujos de restos de comida, gordura, terra ou líquidos**.
- Chegam **sobrepostos e amontoados** uns sobre os outros, impossibilitando a visão isolada de um único item por vez. O modelo treinado puramente neste dataset de laboratório sofrerá de **viés de seleção** e terá uma queda drástica de performance ao ser exposto a dados reais do dia a dia.

5.3 O que o Modelo NÃO Consegue Fazer?

- **Detectar Materiais Compostos:** O modelo falha ao tentar classificar embalagens multicamadas (ex: caixas de leite longa vida, que misturam papelão, plástico e

alumínio). Ele tende a escolher apenas um dos materiais, o que prejudica a qualidade da separação na indústria.

- **Separar Itens Ocultos:** Se uma lata de alumínio estiver escondida dentro de uma caixa de papelão fechada, a câmera de visão computacional registrará apenas o papelão, deixando passar o metal.
- **Garantir a Higiene do Processo:** O modelo não consegue identificar contaminação biológica ou química microscópica nas superfícies dos plásticos que os tornariam impróprios para a reciclagem alimentícia.

6. CONCLUSÃO E PRÓXIMOS PASSOS

Neste projeto, desenvolvemos um modelo de classificação de resíduos utilizando técnicas de Deep Learning e Visão Computacional. Conseguimos criar um modelo robusto baseado em ResNet50 que alcançou uma acurácia de 89,5% utilizando ajuste fino e prevenção ativa de overfitting (Data Augmentation e Dropout).

O projeto prova que a Inteligência Artificial é perfeitamente viável para classificar materiais recicláveis em alta velocidade, superando as limitações de sistemas estáticos de programação e abrindo caminho para modernizar a cadeia de reciclagem nacional.

6.1 O que Fariamos com Mais Um Mês de Desenvolvimento?

Se tivéssemos mais 30 dias de projeto, focaríamos nas seguintes melhorias para levar o modelo do laboratório para o mercado real:

1. **Migração para Detecção de Objetos com YOLOv8:** Em vez de apenas classificar uma única imagem contendo um único lixo (Image Classification), migraríamos o modelo para a arquitetura YOLOv8 (You Only Look Once). Isso permitiria detectar, localizar (por caixas delimitadoras) e classificar **múltiplos objetos de resíduos ao mesmo tempo em uma esteira rápida em movimento**, simulando perfeitamente a operação industrial de triagem.
2. **Criação de um Dataset de "Mundo Real" em Cooperativas:** Montaríamos uma estrutura simples de câmera acima da esteira de uma cooperativa local para coletar e rotular cerca de 5.000 imagens de resíduos reais: amassados, sujos e sobrepostos. Reajustar o modelo com essas imagens eliminaria o viés do fundo branco do Kaggle e garantiria a robustez do sistema no ambiente industrial real.
3. **Segmentação de Instância para Cálculo de Volume:** Implementaríamos modelos de segmentação (como Mask R-CNN) para delinear o contorno exato de cada objeto. Com o contorno e as dimensões em pixels, estimaríamos o volume de plástico, papel e metal processados por minuto na esteira, gerando um painel de dados em tempo real (dashboard de produtividade) para a gerência da usina de triagem.
4. **Compressão de Modelo (Quantização e Poda):** Para permitir que o modelo rode localmente de forma econômica em computadores pequenos acoplados à esteira (como um Raspberry Pi com acelerador Coral Edge TPU), aplicaríamos técnicas de quantização (reduzindo os pesos de float32 para int8). Isso diminuiria o tamanho do modelo e o tempo de processamento, sem perda significativa de acurácia.

7. REFERÊNCIAS

- ASSOCIAÇÃO BRASILEIRA DE EMPRESAS DE LIMPEZA PÚBLICA E RESÍDUOS ESPECIAIS (ABRELPE). Panorama dos Resíduos Sólidos no Brasil 2025. São Paulo: *ABRELPE*, 2025. Disponível em: <https://abrelpe.org.br/>. Acesso em: 16 jul. 2026.
- ÍNDICE de reciclagem no Brasil é de apenas 4%, diz Abrelpe. *Agência Brasil, Brasília*, 5 jun. 2022. Disponível em: <https://agenciabrasil.ebc.com.br/geral/noticia/2022-06/indice-de-reciclagem-no-brasil-e-de-apenas-4-diz-abrelpe>. Acesso em: 16 jul. 2026.
- GARBAGE Classification Dataset. [S. l.]: *Kaggle*, 2018. Disponível em: <https://www.kaggle.com/datasets/asdasdasdasdasd/garbage-classification>. Acesso em: 16 jul. 2026.
- HE, Kaiming et al. Deep residual learning for image recognition. In: Proceedings of the IEEE conference on computer vision and pattern recognition (CVPR). [S. l.: s. n.], 2016. p. 770-778.
- SANDLER, Mark et al. Mobilenetv2: Inverted residuals and linear bottlenecks. In: Proceedings of the IEEE conference on computer vision and pattern recognition (CVPR). [S. l.: s. n.], 2018. p. 4510-4520.